

Tarea 1 - Big Data

Curso: Big Data - Grupo 33 - B III 2026

Profesor: Gerardo Nereo Campos Araya.

Estudiantes

Andrés Esquivel Valerio 402500696

María Fernanda Granados Arias 402200492

Liz Madriz Rivera 117860659.

Instrucciones de ejecución

Para poder ejecutar el main.py de la tarea, se debe ejecutar en la terminal dentro del contenedor de Docker, el siguiente comando, ubicado en la carpeta **Big_Data_Tarea_01/t1**

```
spark-submit main.py data/ciclista.csv data/ruta.csv data/actividad.csv
```

Para poder ejecutar las pruebas unitarias se debe ejecutar el siguiente comando, ubicado en la carpeta **Big_Data_Tarea_01/t1**

```
pytest tests.py -v
```

Descripción del proyecto

El proyecto implementa una solución utilizando Apache Spark, para pocesar datos de ciclistas, rutas y actividades.

El proyecto permite, la unificación de los datasets, calculo de agregaciones, rankings por provincia y la ejecución de pruebas unitarias para corroborar el funcionamiento de las funciones implementadas.

Estructura del proyecto

```
Big_Data_Tarea_01
├── .
├── ./t1
│   ├── ./t1/conftest.py
│   ├── ./t1/data
│   │   ├── ./t1/data/actividad.csv
│   │   ├── ./t1/data/ciclista.csv
│   │   └── ./t1/data/ruta.csv
│   ├── ./t1/doc
│   │   └── ./t1/doc/ManualEjecucion.pdf
│   ├── ./t1/functions
│   │   └── ./t1/functions/functions.py
│   ├── ./t1/main.py
│   └── ./t1/tests.py
```

```
.  
└─ ./Dockerfile  
  
.  
└─ ./Dockerfile.amd64
```